

Localization of Deep Inpainting Using High-Pass Fully Convolutional Network

论文复现报告

何嘉欣

2023 年 12 月 10 日

摘要

本文是对研究论文《Localization of Deep Inpainting Using High-Pass Fully Convolutional Network》的复现报告。文章首先概述了被研究文献的主要内容和相关背景工作，接着对论文所述方法的不同模块展开了深入讲解。报告详尽叙述了复现实验的具体步骤和技术细节，并对得到的实验结果进行了系统的分析和综合评述。

关键词：多媒体取证；图像篡改；深度学习

1 引言

图像修复技术在计算机视觉领域占据了举足轻重的地位，它旨在补全图像中缺失或损坏的部分，恢复图像的完整性和连贯性。这项技术的应用场景极其丰富，涵盖了图像修饰恢复、创意图像编辑、视频内容修复等多个方面。

图像修复任务的核心是利用图像现有的区域内容来自动化地推断和重建丢失或受损区域，使得最终的图像显得自然且无缝衔接。缺失部分的原因多种多样，可能是由于传输过程中的数据丢包、物理损伤、摄影过程中的遮挡或光照造成的阴影等情况。

在早期的图像修复技术中，方法通常包含点插值、纹理平滑等操作，基于图像本身的纹理和结构特征进行融合处理。自 2000 年左右开始，相继出现的修复方法大致分为基于扩散和基于补丁两大类。基于扩散的策略擅长于修复像老照片中的小裂痕之类的细微缺陷；而基于补丁的方法虽能处理更大范围的缺陷，却往往无法复原不存在于原始图像中的复杂结构或新事物。

随着深度学习技术的崛起和发展，图像修复领域得到了新的活力。卷积神经网络（CNN）和生成对抗网络（GAN）等深度学习工具的运用，使得系统可以从海量的样本数据中学习图像的深层结构和纹理信息。得益于这一学习能力，深度学习方法不仅能够呈现出相当自然的修复效果，还能够创造出完整图像中之前未存在的元素和结构，弥补了传统方法的不足。如今，这种高级别的图像修复技术已经成为计算机视觉与图像处理领域的一个重要和活跃的研究方向。



Figure 1. The man with a bag in the original image (left) is no

图 1. 图像篡改示例

尽管图像修复技术的初衷是为了恢复图像中丢失或受损的部分，但其可能被误用的风险不容忽视。例如，篡改图像以移除关键对象创建虚假场景，或擦除版权标识，已成为潜在滥用的途径。随着深度学习在图像修复领域的应用，所生成细节的逼真度进一步提高，以至于人眼难以辨别篡改。如图 1 所示，采用 Iizuka 等人 [8] 提出的方法，可以从图片中去除一个显著的对象（例如人物），并生成一个在视觉上看起来仍然自然合理的篡改结果。这种对原始图像进行剔除的篡改，如果被用作法庭证据或传播假新闻，将会引发一系列严重问题。

针对图像篡改的识别在图像取证领域已经研究了十多年 [22] [9]，各种检测方法也相继提出，用以识别常见的图像处理 [12] [2] 及篡改操作 [4] [21] [7]。同时，也有许多工作针对传统的图像修复方法的检测 [13] [3] [11] [27]。然而，就在文章发布之际，用于检测基于深度学习的图像修复或篡改操作的研究仍然是空缺的。鉴于深度学习有能力将篡改区域的结构、纹理等与未篡改区域相匹配，使得基于深度学习的图像篡改取证与传统的计算机视觉任务存在显著差异。

鉴于此，文章的作者们强调了评估图像是否被深度修复技术修饰以及确定修饰部位的重要性。作者介绍了一种端到端的篡改区域定位方法，该方法首先分析了篡改后区域与未触及区域间的显著差异。作者观察到，在高通滤波后的图像残差中，这两种区域之间的差异性更加显著。基于此发现，作者设计了一个使用高通滤波器初始化的预滤波模块来提取图像残差，进而增强图像篡改的信号。随后，建立了一个包含四个 ResNet 块 [6] 的特征提取模块，以从残差数据中提取区分特征，并利用一个上采样网络来预测图像中每个像素是否被篡改。作者的实验结果表明，这一方法能高效准确地定位到遭到篡改的特定区域。

2 相关工作

2.1 基于深度学习的图像修复方法

基于深度学习的图像修复技术与传统方法相比，在于其能力来自于借助大规模数据集学到的丰富的图像语义表征。深度学习方法的独特优势在于生成极具逼真细节的修复图像，并在必要时创造出图像中原本不存在的新区域，例如人像中缺失的部分。

深度学习的图像修复通常依赖于一种由两部分组成的网络架构：一个修复网络和一个辅助的判别网络。修复网络负责捕捉图像的深层语义，并推断出待修补区域的内容，也就是说，它实现了将破损的图像转换为修复后的图像的映射。而判别网络则在通过生成对抗的方式训

练中提升嵌入部分的视觉可信度 [5]。

作为早期利用深度网络进行图像修复的创新性尝试之一，上下文编码器 [20] 通过结合像素级重建损失和对抗性损失来训练模型，在 128×128 图像中成功填充了 64×64 的空白区域。Yang 等人 [25] 提出了一种多尺度的神经块合成技术，通过联合优化图像内容和纹理细节达到现实般修复的效果，尽管这种技术在高分辨率的图像上可以产生更清晰的修复结果，但它需要更长的计算时间。

Iizuka 等人 [8] 则引入了全局和局部鉴别器，以确保整体图像及局部修补区域都符合真实感。Liu 等人 [16] 为了防止掩膜空白带来不利影响，设计出了部分卷积，这种特殊形式的卷积遮蔽了卷积过程中未知的部分，只利用图像中的有效像素来预测缺失区域。Yu 等人 [26] 继而探索使用门控卷积来自动遮蔽卷积过程，从而取得更理想的修补效果。Xiong 等人 [24] 则主张一种前景感知的修补策略，该策略将前景轮廓预测作为引导来辅助修补过程。

总体而言，所有这些进展表明，深度学习图像修复技术能够利用复杂的网络结构和创新算法来解决修复任务中最具挑战性的问题，极大地扩展了修复领域的能力边界。

2.2 图像修复取证相关工作

迄今已开发了若干种检测传统图像修复技术的取证方法。Li 等人 [10] 提出了一种技术，利用分析图像拉普拉斯矩阵沿等光子轨迹的局部方差来检测基于扩散的修复方法。针对基于修补 (patch-based) 的修复检测，Wu 等人 [23] 使用零连接长度测度衡量修补之间的相似性。随后，Bacchuwar 等人 [1] 提出了一种基于跳跃的修补匹配方法，以降低计算复杂度。然而，[23] 和 [1] 的方法均须手动选取可疑区域，而且容易出现高误报率。Chang 等人 [3] 为寻找可疑区域提出了一种两步曲搜索策略，并使用多区域关系降低误报率。Liang 等人 [14] 通过中心像素映射方法加速搜寻，并借助最大零连接成分标记来执行破片拼贴检测，达到定位篡改区域的目的。Zhu 等人 [27] 则设计了一种带有编码器-解码器架构的卷积神经网络 (CNN)，专门用于检测基于修补的 256×256 图像修复。

然而，深度修复方法通常会产生更为精细的图像内容，有时甚至在修复区域内创造全新对象，从而在篡改痕迹上与传统方法大相径庭。由此可见，针对传统修复技术的取证方法并不适合定位深度修复产生的痕迹。

考虑到深度修复模型通常是采用生成对抗网络 (GAN) 训练出来的，一些近期关于生成图像检测的研究 [18] [19] [10] 也许可以应用于深度修复的定位任务。另一方面，特定于图像拼接定位的算法 [21] [7] 可能同样适用于修复区域的定位。但是，这些方法并没有特别针对由深度学习修复技术留下的特殊痕迹，据我们的实验验证，它们在此类场景下的表现并不尽如人意。

3 本文方法

3.1 本文方法概述

此该方法采用三个模块对图像中的篡改模块进行定位，如图 2 所示：




Figure 2 Basic framework of the proposed method

图 2. 文中网络结构图

本方法精心设计了三个模块顺序协同工作以实现准确的图像篡改定位。首先，通过使用高通滤波器初始化的预滤波模块，对图像中的修改迹象进行增强，使得篡改部分的区分更加突出；随后，依托四个精细构建的残差网络（ResNet）块，把握图像特征并学习区分篡改与未篡改区域；最终，通过上采样模块对这些学习到的特征进行放大，以达到像素级别的精准预测。

值得一提的是，该网络是一个无需全连接层的全卷积网络（FCN） [17]，它具有弹性的特性，使得网络能在不同尺寸的图像上自如作业，并无需特定大小的输入限制。在整个网络的训练过程中，采用了焦点损失函数以应对篡改像素和未篡改像素之间存在的显著数量差异，从而调和不平衡的数据分布并优化模型的学习效果。

在接下来的章节中，我们将详尽介绍该方法的具体技术细节，并深入探讨其组成部分的内在机制与彼此间的相互作用。通过这种分层次的方法论，旨在为读者清晰地展示如何通过综合应用多个模块和不同技术手段，整合为解决复杂图像篡改检测问题的高效网络架构。

3.2 高通滤波模块

本研究首先利用经高通滤波器初始化的预滤波模块，意在增强图像中的篡改迹象。高通滤波的核心目的在于压制图像中占主导的低频成分，同时强调那些描绘图像尖锐边缘和精细细节的高频信息。该过程引出了图像的残差——一种保留的高频成分，这部分信息揭示了图像中潜在的、不易察觉的细微变化。

图像篡改处理会在图像中引入额外信息或者改变原有内容，从而在原图与篡改图之间形成对比。当图像被高通滤波时，普通场景的常规内容由于频率较低而被抑制，相对的，篡改区域内包含的、异常的高频信息（残差）会因此更加明显，正如图 3 所展示的那样。这种增强后的注目点，允许分析人员更加轻松地辨认出图像中的篡改部分。篡改往往会引致在图像的特定区域产生非典型的高频活动。据此，高通滤波在图像的取证和安全领域被广泛采用，以揭示和检测图像篡改或伪造行为，对于恢复图像的真实性提供了一种有效的技术手段。

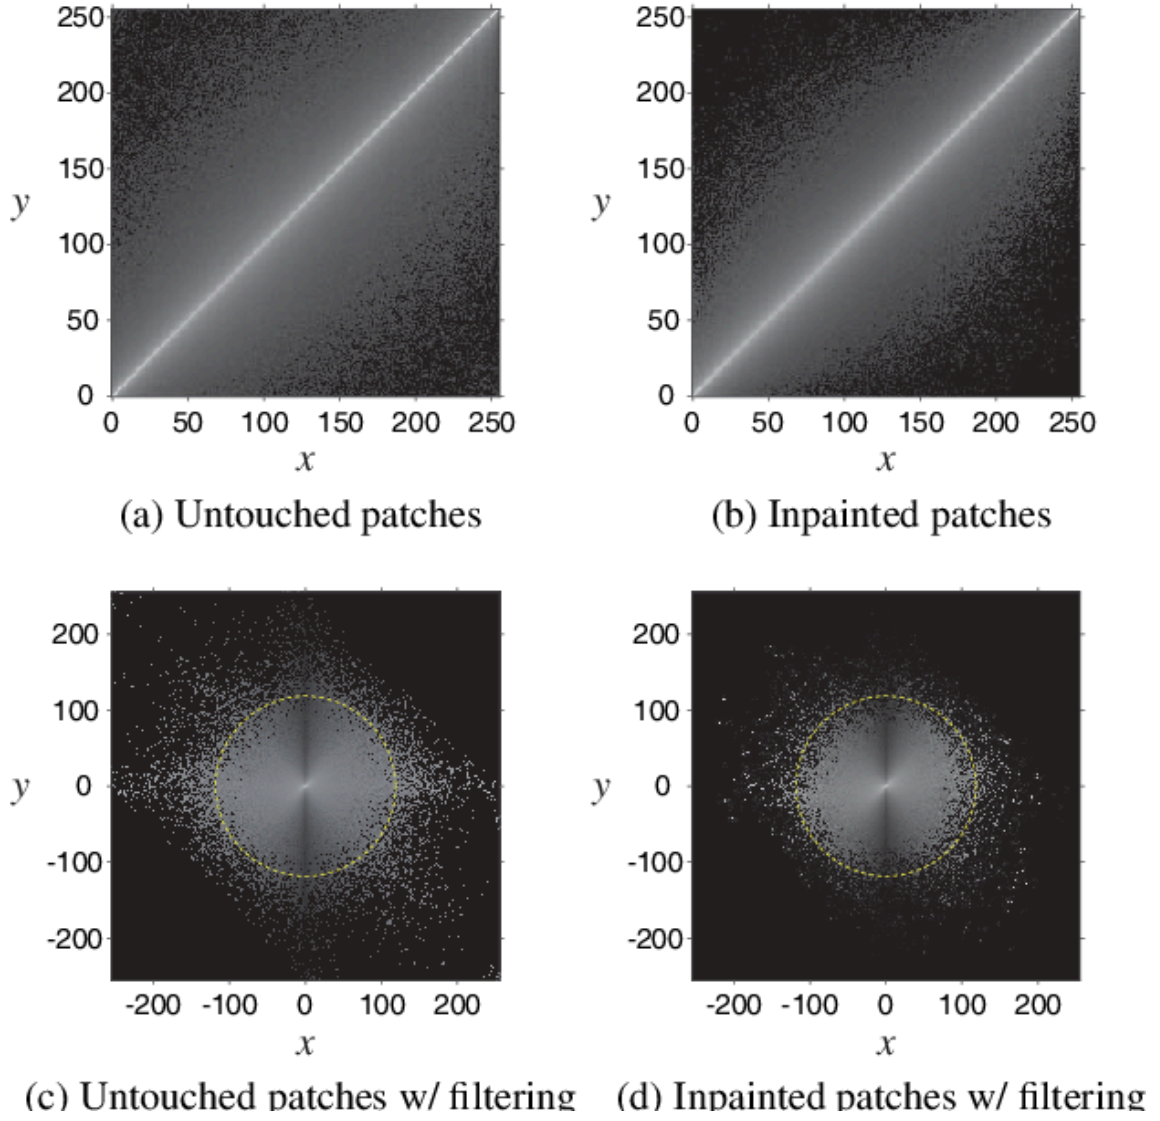


图 3. 高通滤波的未篡改/已篡改图像的转移概率矩阵

在本研究所使用的方法中，开发了一个精心设计的预滤波模块，专门用于初步处理进入网络的图像。这一模块借助于步幅设置为 1 的深度卷积来实施，有效地增强了输入图像中的细节特征。具体操作为，将输入图像的每个颜色通道独立地与一组预定的高通滤波器核（详见图 4）进行卷积作业，该组滤波器核旨在挖掘图像的高频信息。随后，各通道得到的卷积响应（即图像的高频残差）拼接成一体，整合为一个更丰富的特征集，供网络的后续层进一步加工利用。

值得一提的是，这种预滤波方式的初始设定采用了三个不同方向的一阶导数滤波器。这样的选择基于它们在图像处理中对边缘和纹理信息捕捉的敏锐性——通过捕获图像梯度，这些高通滤波器对于揭示图像区域间微妙的变化尤其有效。此举旨在确保模型从一开始就能够注意到可能包含关键篡改线索的细节变化，从而为之后的图像篡改检测任务打下坚实基础。

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & -1 & 1 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

图 4. 预过滤模块的初始化过滤器内核

为了能够精确地辨别嵌入区域与未受影响区域，特征提取模块的设计致力于从预处理过的图像残差中提取出既丰富又具区分性的特征。这一过程关键在于识别哪些特征最能代表已进行干预的部分以及维持原貌的部分，确保模块能够有效调和并利用这些特征以达到分类的准确性，从而为后续分析提供清晰的差异化信号。

3.3 特征提取模块

所设计的特征提取模块架构精巧，整体由四个由残差网络（ResNet）结构框架搭建的基础块构成，其中每个基本块由两个精心设计的“瓶颈”单元组成。这些瓶颈单元各包括三个卷积层，它们与一个保持恒等映射的跳跃连接（或称快捷连接）相结合。在进行卷积操作之前，每层都会执行批量归一化处理，并采用 ReLU 函数进行激活。这些构成瓶颈结构的卷积层具有不同的核尺寸，顺序为 1×1 、 3×3 和 1×1 ，旨在通过该结构实现有效的特征提取与变换。在绝大部分层中，卷积步幅被设置为 1；而在每个基础块的第二个单元的最后一卷积层，步幅则被增加至 2，这一改变致使该层兼具池化功能，减少了数据的空间分辨率。

符合残差网络的传统设计精神，作者的方法规定了前两个卷积层（瓶颈层）的通道深度相对于第三个卷积层（输出层）的 $1/4$ 。文章中详述，第一个基础块的输出深度被确定为 128，并保证在后续每增加一个基础块，输出深度相应翻倍。

如图 5 所详细展示，该特征提取模块以具有 9 个通道的图像残差为输入，并经由训练学习，最终能够生成 1024 个特征图。值得注意的是，生成的这些特征图保持着原始输入图像 $1/16$ 的空间分辨率，这一创新设计有效地融合了卷积神经网络深层特征学习的优势，并显著提升了图像处理任务的效能。

Block	Bottleneck unit	Bottleneck depth	Output depth	Output stride
#1	#1	32	128	1
	#2	32	128	2
#2	#1	64	256	1
	#2	64	256	2
#3	#1	128	512	1
	#2	128	512	2
#4	#1	256	1024	1
	#2	256	1024	2

Table 1. The architecture settings of the feature extraction module.

图 5. ResNet 设置

3.4 上采样模块

鉴于特征提取模块降低了空间分辨率，输出的特征图中的每个像素点实际上代表了输入图像中某一个较大区域的信息。为了在这种缩约的特征空间中对每个像素点赋予适当的类别标签，研究方法采用了转置卷积操作以放大特征图的空间分辨率。初始时，转置卷积层使用双线性核进行初始化，并且允许核参数在训练阶段得以学习优化。

如果直接将特征图一步上采样至输入图像的原始大小（相当于 16 倍上采样），将需要极其庞大的卷积核（ 32×32 ），这会大幅增加训练过程的难度。为了避免这一问题，研究者们设计了一个分阶段的两级上采样策略：首先将空间分辨率通过两个连续的转置卷积层提升 4 倍。这一巧妙的做法显著减小了所需核的尺寸，最终使用的为 8×8 。

正因上采样操作并不会增进原有的信息量，作者在两次转置卷积之间对特征图的通道深度进行了精心设计以保留足够的特征。因此，两个转置卷积层的输出通道被设定为 64 和 4。为了进一步抑制转置卷积所可能引入的棋盘效应，研究引入了一个额外的 5×5 卷积核，步长为 1，这不仅缓解了棋盘效应，还将 4 通道的输出转换为 2 通道，为进一步的分类决策铺垫。最终，经过一个 softmax 层进行分类，生成了一个提供像素级别预测的精确的篡改定位映射。这一系列设计和实施的措施，充分考虑了特征提取与像素级分类的有效结合，保证了输出映射的高质量 and 模型的鲁棒性。

3.5 损失函数定义

在图像篡改检测的场景中，篡改区域的大小通常远远小于未经修改的部分，导致在样本中出现显著的类别不平衡现象。依靠传统的交叉熵损失函数对网络进行训练时，数量庞大的负样本（未篡改区域）会对损失值产生主要贡献，并且主导梯度更新，导致模型在训练后易于正确分类负样本，同时却对正样本（篡改区域）的识别性能不佳。这种倾向性降低了模型的真阳性率，从而影响了篡改部分的精确识别。

为了缓解由类别不平衡引起的影响，研究者采纳了焦点损失函数 [15]，这种损失函数是

对标准交叉熵损失的一种扩展。焦点损失通过引入一个调制因子，降低了对分类任务影响显著而且容易分类的负样本对总损失的贡献，使网络优化过程更关注误分类的阳性样本。据实验证明，焦点损失在性能上优于传统交叉熵损失以及加权版交叉熵损失，特别是在处理具有类别不平衡问题的情况时更为显著。因此，在训练过程中运用焦点损失，模型更能有效地识别并正确分类图像篡改区域，提升了模型在这一关键任务上的整体性能。

4 复现细节

4.1 与已有开源代码对比

该论文所提出的方法代码已经在 GitHub (https://github.com/lihaod/Deep_inpainting_localization) 上以开源形式提供。本复现工作在深入分析原始公开代码的基础上，特别聚焦于高通滤波器在增强图像篡改迹象方面的双刃剑效应——尽管可以更明显地显示出图像的修改痕迹，但同时不可忽视的是对于图像中低频信息的潜在抑制作用。这点尤为关键，因为图像篡改往往涉及到低频内容的修改，例如通过精细调整背景或移除关键特征来操纵图像。

为了弥补此一方法潜在的不足，并进一步提升对篡改区域识别的精准度，本复现进程调整了原有网络结构，如图 6 所示。通过引入双重 ResNet 模块的策略，一方面处理未经高通滤波的原始图像，另一方面处理经过高通滤波后的图像，两者的输出随后被合并。这种创新的结构设计使得网络不但考虑到了高频信息，在篡改检测时，同样对低频信息赋予了适当的重要性。最终，此一结合了两条路径的输出的网络模型能够提供一个更为全面和均衡的篡改预测结果。




图 6. 改进后网络结构示意图

4.2 实验环境搭建

本实验在如下（表1）软硬件环境中运行。

软硬件名称	版本配置
GPU	GTX 1080 Ti
CUDA	10.0
Python	3.6
Tensorflow-gpu	1.13.2

表 1. 实验环境配置

4.3 创新点

文章是首个针对基于深度学习的图像篡改检测模型的提出者。独特之处在于，作者不仅区分了篡改区域和未篡改区域之间的显著特征，还首次提出了一种使用高通滤波器对待检测图像实施预处理的策略。在仔细研究和复现这篇文章的过程中，笔者经过深思熟虑，认识到高通滤波虽能有效地突出图像的篡改痕迹，但它也可能同时削弱了图像中的低频信息。考虑到图像篡改区域可能主要由低频信息构成——如通过细化背景或移除某些细节来实施篡改——将保留的低频内容纳入篡改检测判据是有其合理性的。因此，笔者提出了将未经高通滤波处理的原始图像或经过低通滤波处理的图像引入神经网络中的新方法，如图 6 所示。具体而言，原图或低通滤波后的图像将通过一个独立的 ResNet 模块处理，并与经过高通滤波器和 ResNet 模块的图像输出相结合，从而形成最终的篡改区域预测结果。

5 实验结果分析

在本部分的实验中，笔者分别对原文方法、加入低通滤波后的方法、低通滤波后经 ReLU 的方法以及仅使用低通滤波后的方法进行实验与对比。得到结果如表 2 所示。

实验数据:QF96	原文方法	加入低通滤波	加入低通滤波与 ReLU	仅有低通滤波
ACC	0.926219	0.914252	0.931028	0.928761
Recall	0.655603	0.668144	0.649028	0.000003
Prec	0.633804	0.613002	0.645472	0.005263
F1	0.584771	0.573487	0.586039	0.000005
IoU	0.447658	0.437226	0.447722	0.000003

表 2. 实验结果 1

使用原文方法进行定位效果对比如图 7 8 所示。




图 7. 掩码图像




图 8. 定位预测图像

基于上述研究成果，显而易见的是，高通滤波器在揭示图像篡改信息方面扮演了关键角色。该方法对高频成分进行强调，结果表明，这些高频内容在检测和定位篡改区域时比低频信息提供了更大的贡献。虽然通过引入低通滤波的处理，模型的准确性确实略有提高，但分析显示，对模型性能影响最显著的依然是高频特征。特别是在只使用低通滤波器的场景中，其在准确定位篡改区域方面的性能表现极为不佳。这一发现表明，虽然低频特征可能对图像篡改定位起到了一定的支持作用，但高频信息才是起决定性影响的因素。

同时，值得注意的是，由于实验是在受限的硬件条件下进行的，实验轮数只能维持在相对较低的水平，这可能使得所获结果的精确度稍逊于原始研究。然而，尽管如此，基于复现实验的一致性和有效性，我们有理由相信原始研究的发现是可靠的。通过这一复现研究，我们不仅对原论文中提出的方法有了更深的认识和理解，而且对于图像篡改检测领域的未来研究方向也提供了积极的展望和信心。

进一步地，本研究也着重验证了模型在不同数据集上的泛化效能。具体来说，我们将在数据集 QF96 上经过训练的模型，应用于 QF75 数据集，以测试其在新环境下对图像篡改位置的识别能力。下图分别展示了两个数据集的原始图像和对应的篡改区域掩码，为我们评估模型在处理这些图像时的效果提供了直观参考。实验结果如表3所示。可以看出，模型的泛化能力有待加强。



图 9. QF96 原图




图 10. QF96 掩码图像



图 11. QF75 原图



图 12. QF75 掩码图像

实验数据:	QF96	QF75
ACC	0.978909	0.927762
Recall	0.822872	0.446419
Prec	0.903031	0.791063
F1	0.843338	0.512245
IoU	0.753709	0.383489

表 3. 实验结果 2

6 总结与展望

论文提出了一种利用深度学习技术进行图像修复的先进方法，尤其注重在全卷积网络 (FCN) 的框架下，如何借助高通滤波器来提升修复质量。作者细致构建了三大核心模块来精确定位图像的篡改区域：首先启用高通滤波器以凸显图像痕迹；继而通过 ResNet 块的强大学习能力，进行区域特征的深度分析与学习；最后，通过一个高效的上采样模块，实现了精确的像素级预测，精妙地完成了篡改区域的精准识别。

此外，为了解决图像修复过程中篡改与未篡改区域比例失衡的问题，该研究引入了创新的焦点损失函数，有效减轻了由类别不平衡引起的不利影响，从而在修复结果中确保了更高的精确度和一致性。

在针对论文方法的复现过程中，笔者验证了原文研究所描述的篡改定位能力。使用高通滤波处理的图像残差成功增强了篡改区域的信号，突出了高频部分与未篡改区域的差异。此复现工作基于原作者所提供的开源代码，进一步对模型进行实验和测试。

实验结果表明，高频成分在图像篡改定位中的关键作用不言而喻，而同时引入的低频信号对定位任务起到了有效的辅助作用，这一发现指向了将图像的低频成分纳入分析能显著提升模型的整体性能。尽管如此，模型在泛化能力的测试中表现较为受限，揭示了今后工作的改进方向，即进一步增强模型对不同数据集和条件的适应性和泛化性能，从而推进深度学习在图像修复领域的应用和研究。

参考文献

- [1] Ketan S Bacchuwar, KR Ramakrishnan, et al. A jump patch-block match algorithm for multiple forgery detection. In *2013 International Mutli-Conference on Automation, Computing, Communication, Control and Compressed Sensing (iMac4s)*, pages 723–728. IEEE, 2013.
- [2] Belhassen Bayar and Matthew C Stamm. Constrained convolutional neural networks: A new approach towards general purpose image manipulation detection. *IEEE Transactions on Information Forensics and Security*, 13(11):2691–2706, 2018.
- [3] I-Cheng Chang, J Cloud Yu, and Chih-Chuan Chang. A forgery detection algorithm for exemplar-based inpainting images using multi-region relation. *Image and Vision Computing*, 31(1):57–71, 2013.
- [4] Vincent Christlein, Christian Riess, Johannes Jordan, Corinna Riess, and Elli Angelopoulou. An evaluation of popular copy-move forgery detection approaches. *IEEE Transactions on information forensics and security*, 7(6):1841–1854, 2012.
- [5] Ian Goodfellow, Jean Pouget-Abadie, Mehdi Mirza, Bing Xu, David Warde-Farley, Sherjil Ozair, Aaron Courville, and Yoshua Bengio. Generative adversarial nets. In Z. Ghahramani, M. Welling, C. Cortes, N. Lawrence, and K.Q. Weinberger, editors, *Advances in Neural Information Processing Systems*, volume 27. Curran Associates, Inc., 2014.
- [6] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Identity mappings in deep residual networks. In *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14*, pages 630–645. Springer, 2016.
- [7] Minyoung Huh, Andrew Liu, Andrew Owens, and Alexei A Efros. Fighting fake news: Image splice detection via learned self-consistency. In *Proceedings of the European conference on computer vision (ECCV)*, pages 101–117, 2018.
- [8] Satoshi Iizuka, Edgar Simo-Serra, and Hiroshi Ishikawa. Globally and locally consistent image completion. *ACM Transactions on Graphics (ToG)*, 36(4):1–14, 2017.
- [9] Paweł Korus. Digital image integrity—a survey of protection and verification techniques. *Digital Signal Processing*, 71:1–26, 2017.
- [10] Haodong Li, Bin Li, Shunquan Tan, and Jiwu Huang. Identification of deep network generated images using disparities in color components. *Signal Processing*, 174:107616, 2020.
- [11] Haodong Li, Weiqi Luo, and Jiwu Huang. Localization of diffusion-based inpainting in digital images. *IEEE transactions on information forensics and security*, 12(12):3050–3064, 2017.

- [12] Haodong Li, Weiqi Luo, Xiaoqing Qiu, and Jiwu Huang. Identification of various image operations using residual-based features. *IEEE Transactions on Circuits and Systems for Video Technology*, 28(1):31–45, 2016.
- [13] Xiang Hua Li, Yu Qian Zhao, Miao Liao, Frank Y Shih, and Yun Q Shi. Detection of tampered region for jpeg images by using mode-based first digit features. *EURASIP Journal on advances in signal processing*, 2012:1–10, 2012.
- [14] Zaoshan Liang, Gaobo Yang, Xiangling Ding, and Leida Li. An efficient forgery detection algorithm for object removal by exemplar-based image inpainting. *Journal of Visual Communication and Image Representation*, 30:75–85, 2015.
- [15] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. Focal loss for dense object detection. In *Proceedings of the IEEE international conference on computer vision*, pages 2980–2988, 2017.
- [16] Guilin Liu, Fitsum A Reda, Kevin J Shih, Ting-Chun Wang, Andrew Tao, and Bryan Catanzaro. Image inpainting for irregular holes using partial convolutions. In *Proceedings of the European conference on computer vision (ECCV)*, pages 85–100, 2018.
- [17] Jonathan Long, Evan Shelhamer, and Trevor Darrell. Fully convolutional networks for semantic segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 3431–3440, 2015.
- [18] Francesco Marra, Diego Gragnaniello, Davide Cozzolino, and Luisa Verdoliva. Detection of gan-generated fake images over social networks. In *2018 IEEE conference on multimedia information processing and retrieval (MIPR)*, pages 384–389. IEEE, 2018.
- [19] Huaxiao Mo, Bolin Chen, and Weiqi Luo. Fake faces identification via convolutional neural network. In *Proceedings of the 6th ACM workshop on information hiding and multimedia security*, pages 43–47, 2018.
- [20] Deepak Pathak, Philipp Krahenbuhl, Jeff Donahue, Trevor Darrell, and Alexei A Efros. Context encoders: Feature learning by inpainting. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 2536–2544, 2016.
- [21] Ronald Salloum, Yuzhuo Ren, and C-C Jay Kuo. Image splicing localization using a multi-task fully convolutional network (mfcn). *Journal of Visual Communication and Image Representation*, 51:201–209, 2018.
- [22] Matthew C Stamm, Min Wu, and KJ Ray Liu. Information forensics: An overview of the first decade. *IEEE access*, 1:167–200, 2013.
- [23] Qiong Wu, Shao-Jie Sun, Wei Zhu, Guo-Hui Li, and Dan Tu. Detection of digital doctoring in exemplar-based inpainted images. In *2008 international conference on machine learning and cybernetics*, volume 3, pages 1222–1226. IEEE, 2008.

- [24] Wei Xiong, Jiahui Yu, Zhe Lin, Jimei Yang, Xin Lu, Connelly Barnes, and Jiebo Luo. Foreground-aware image inpainting. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 5840–5848, 2019.
- [25] Chao Yang, Xin Lu, Zhe Lin, Eli Shechtman, Oliver Wang, and Hao Li. High-resolution image inpainting using multi-scale neural patch synthesis. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6721–6729, 2017.
- [26] Jiahui Yu, Zhe Lin, Jimei Yang, Xiaohui Shen, Xin Lu, and Thomas S Huang. Free-form image inpainting with gated convolution. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 4471–4480, 2019.
- [27] Xinshan Zhu, Yongjun Qian, Xianfeng Zhao, Biao Sun, and Ya Sun. A deep learning approach to patch-based image inpainting forensics. *Signal Processing: Image Communication*, 67:90–99, 2018.